

- 1
- 2
- 3
- 4
- 5
- 6
- 7
- 8
- 9
- 10
- 11
- 12
- 13
- 14
- 15
- 16
- 17
- 18
- 19
- 20
- 21
- 22
- 23
- 24
- 25
- 26
- 27
- 28
- 29
- 30
- 31
- 32
- 33
- 34
- 35
- 36
- 37
- 38
- 39
- 40
- 41
- 42
- 43
- 44
- 45
- 46
- 47
- 48
- 49

Additional Key Words and Phrases: LLM agents, Model Context Protocol, tool surface, least privilege, configuration analysis, information flow, prompt injection, empirical study

Anonymous Author(s). 2026. INTERLOCK. 1, 1 (September 2026), 9 pages. <https://doi.org/10.1145/nnnnnnnn.nnnnnnnn>

MCP(Model Context Protocol)는 LLM 에이전트가 외부 도구를 받아오는 사실상의 표준이 되었다 [8]. 사용자는 설정 파일에 서버 집합을 적고, 각 서버를 실행할 명령이나 원격 엔드포인트, 서버가 받을 자격증명, 그리고 일부 서버의 경우 어떤 도구를 광고할지 정하는 플래그를 지정한다. 호스트는 각 서버를 띄워 도구 목록을 받아 오고, 반환된 이름과 설명, 스키마를 모델의 컨텍스트에 넣는다. 한 세션에서 이렇게 모인 도구 전체를 우리는 그 배포의 *tool surface*라 부른다. 여기서 두 가지가 보안을 좌우한다. *surface* 위의 모든 도구는 호출 가능하다. 도구 선택은 광고된 텍스트를 읽은 모델이 하며, 에이전트가 읽는 콘텐츠를 통제하는 공격자는 그 선택을 유도할 수 있기 때문이다 [33]. 그리고 *surface*를 정하는 주체는 제공자가 아니라 사용자다. 즉 이를 좁힐 수 있는 유일한 당사자도 사용자다.

이 증위를 보호하는 연구는 네 갈래로 요약된다. 개별 도구를 검사하는 연구는 광고된 설명에서 숨겨진 지시와 이름 가로채기, 유출 엔드포인트를 탐지하고 신뢰할 수 있는 설명을 재생성한다 [12, 27, 31]. 개별 서버를 검사하는 연구는 서버 구현 내부의 taint 계열 결함을 정적으로 찾고, 실행 중 도구 동작을 감사한다 [25, 26]. 제공자 집합을 판단하는 연구는 비공개 데이터와 신뢰할 수 없는 콘텐츠, 외부 통신이 함께 모이는 조합을 위험으로 지목하고, 정책을 위반할 도구 순서를 구성해 점수화하거나 누적 노출로 세션을 취소한다 [2, 21, 28]. 실행 시점에 에이전트를 제약하는 연구는 신뢰된 질의에서 흐름을 추출하거나 라벨을 추적해 호출마다 최소 권한을 집행한다 [6, 7, 23]. 공격 연구도 같은 대상으로 옮겨 가, 페이로드를 여러 도구에 나누어 심는 임계값 오염을 수행하거나 합법적인 도구들을 조율된 워크플로로 조립한다 [15, 33].

이 성과들은 하나의 작동 지점을 공유한다. 모두 제공자가 출하한 그대로의 surface를 판단하거나 제약한다. 그래서 사용자가 실제로 행동할 수 있는 질문, 즉 설치한 surface 가운데 무엇을 설정 자체에서 끄면 설치 목적을 잃지 않고 위험을 줄일 수 있는가는 아무도 계산하지 않는다. 우리는 이 공백이 실제로 문제가 되는지 측정했다. 공개된 설정 19,777개를 수집하고, 가장 자주 설정되는 서버 17개의 모든 도구에 대해 서버 자신의 소스 코드에서 효과마다 파일과 줄 번호를 인용해 효과를 도출한 결과, 그 서버들로부터 구성된 설정 880개 가운데 84.1%가 한 세션 안에서 비공개 데이터와 공격자가 통제하는 콘텐츠, 공격자가 읽을 수 있는 목적지에 모두 닿는다. 그 전부에서 서버 하나가 이미 단독으로 그 조합을 완성하므로 제공자 사이의 조합은 결정적 요인이 아니고, 따라서 제공자 사이 흐름만 끊는 방어는 이 설정들을 하나도 구하지 못한다. 그런데 surface를 좁힐 수 있는 제어 수단은 존재하는 곳에서 거의 쓰이지 않고(코드 호스팅 서버의 읽기 전용 모드는 항목 189개 중 3개) 주요 원인 서버에는 아예 없다(브라우저 자동화 서버의 코드 실행

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, to republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

도구를 끄는 플래그는 없다). 경고 역시 이 기저울에서는 무력하다. 설정의 84%에 경고를 띄우면 사용자가 할 수 있는 일은 무시하는 것뿐이다.

이 논문에서 우리는 INTERLOCK을 제시한다. 이는 에이전트 설정에 대해 최소 권한 tool surface를 계산하는 새로운 접근으로, 판정이 아니라 사용자가 적용할 수 있는 설정 변경을 출력한다. INTERLOCK은 설정과 흐름 정책, 배포가 선언한 작업을 입력으로 받아 세 단계로 동작한다. 먼저 Summarize가 신뢰도 순으로 정렬한 증거에서 도구별 효과 요약과 요약을 만든다. 다음으로 Decide가 설정이 지정한 값 수준 조건을 적용한 뒤 유도된 surface 위에서 정책을 평가하고, 금지된 흐름마다 그것을 증언하는 도구를 반환한다. 끝으로 Repair가 호스트와 서버가 이미 제공하는 제어 수단 – 도구 단위 거부 항목, 서버 모드와 toolset 플래그, 인자 축소, 그리고 가장 비싼 선택지인 서버 제거 – 위에서 최소 비용 patch를 합성하되 선언된 작업을 보존하며, 결과를 설정 diff로 내보낸다. 집행에는 호스트 변경이 필요 없다. 호스트는 이미 도구 단위 허용·거부 목록을 받아들이고 서버는 이미 모드 플래그를 받아들이기 때문이다.

이 접근의 핵심 난점은 효과를 무엇에서 읽어낼 것인가에 있다. 도구가 무엇에 닿는지는 어디에도 기계가 읽을 수 있는 형태로 선언되어 있지 않다. 스키마는 파라미터의 모양만 말하고, 설명은 판정 대상인 제공자가 쓴 자유 서술이라 공격자가 통제할 수 있으며, 정적 분석만으로 배포된 패키지 전체를 따라가는 것은 규모가 맞지 않는다. 이 난점을 해결하기 위해 우리는 신뢰도 순위를 매긴 요약과 결정적 재검사를 결합한 절차를 만들었다. 언어 모델이 서버의 소스 코드를 읽고 도구마다 효과를 판정하되 모든 주장에 file:line 증거를 인용하게 하고, 결정적 검사기가 가져온 소스에서 그 구간을 다시 읽어 확인되지 않은 주장을 걸러낸다. 확인되지 않은 주장은 버려지지 않고 미확인으로 표시된 채 라벨을 유지하며, 모델이 판정하지 않은 도구에는 가장 보수적인 값을 부여하고, 문서만을 근거로 한 "무해" 판정은 무해로 세지 않는다. 문서는 효과의 부재를 입증할 수 없기 때문이다. 이 구성 덕분에 출력은 그럴듯한 요약이 아니라 독자가 코드 한 줄로 되짚을 수 있는 감사 가능한 기록이 된다.

Contributions. We summarize our contributions as follows:

- **Observation:** 우리는 에이전트 설정을 대상으로 trifecta-completeness와 capability bundling을 조작적으로 정의하고, 공개 설정 19,777개와 코드에서 도출한 효과 요약으로 이를 측정한다. 분석 가능한 설정의 84.1%가 위험한 조합을 완성하고, 그 전부에서 단일 제공자로 충분하며, 좁힐 수단은 쓰이지 않거나 없다는 것을 보인다.
- **New technique:** 우리는 설정에 대한 최소 권한 tool surface 합성을 정식화하고 INTERLOCK을 제시한다. 기술적 기여는 공격자가 쓸 수 있는 산문을 결코 신뢰하지 않는 신뢰도 순위 효과 요약, 각 후보 patch 이후 다시 판정하는 witness 유도 수선, 그리고 제공자가 surface를 바꿀 때 캐시된 요약에 대해 다시 판정하는 것이다.
- **Evaluation:** 우리는 효과 요약 단계를 구현해 서버 34개와 도구 433개에서 평가하고, 모델 판정 가운데 결정적 재검사를 통과하는 비율(전체 72.5%, 구현 코드가 배포되는 경우 90.7%)과 통과하지 못하는 세 가지 구조적 한계를 보고한다. 도구와 설정 코퍼스, 판정된 효과 요약을 공개한다.

2 Background and Threat Model

2.1 Tool surfaces and who decides them

호스트 애플리케이션 – IDE 어시스턴트, 데스크톱 에이전트, 코딩 에이전트 – 은 설정 파일에 명시된 각 Model Context Protocol 서버를 실행하고 도구 목록을 요청한 뒤, 반환된 이름과 설명, JSON 스키마를 모델의 컨텍스트에 넣는다. 서버는 명령줄로 실행되는 로컬 프로세스일 수도, 컨테이너일 수도, 원격 엔드포인트일 수도 있으며, 스킴 번들이 서버를 추가로 기여하기도 한다. 한 세션에서 광고된 도구들의 합집합을 우리는 그 배포의 tool surface라 부른다. 이 구조의 세 가지 성질이 이후 논의를 이끈다. surface는 개별 제공자가 아니라 사용자의 설정이 결정한다. surface

Table 1. Configuration corpus mined from public GitHub. Entries are server declarations; one configuration may declare several.

Configurations (deduplicated, non-fork)	19,777
declaring a single server	10,532
declaring two or more servers	9,302
Server entries by kind: npm	22,010
remote endpoint	14,250
other command	7,564
local script	7,284
PyPI	3,156
container image	1,507
Stdio entries launched without a version pin	24,354 / 26,673 (91.3%)

위의 모든 도구는 호출 가능하다. 도구 선택은 광고된 텍스트를 읽은 모델이 하기 때문이다. 그리고 *surface*는 고정되어 있지 않다. 호스트는 대개 버전을 고정하지 않은 패키지 지정으로 서버를 실행하므로, 도구 뒤의 코드는 사용자가 아무 행동을 하지 않아도 세션 사이에 바뀔 수 있다.

2.2 Threat model

우리는 에이전트가 자신이 읽은 콘텐츠 안의 지시를 따른다고 가정한다. 이는 *lethal trifecta* 프레임 [28]과 *toxic-flow* 분석 [2]이 전제하는 가정이며, 이 층위에 대해 공개된 공격들이 실제로 악용하는 가정이다 [15, 32, 33]. 공격자는 임의의 웹 호스트와 콘텐츠를 통제하고, 여러 사람이 쓸 수 있거나 제3자가 제공하는 출처의 콘텐츠 – 공개 이슈와 댓글, 저장소 내용, 커뮤니티 문서와 레지스트리, 검색 결과 – 도 통제한다. 공격자는 사용자의 로컬 파일이나 사용자 계정에 담긴 데이터를 통제하지 못하며, 설치된 서버를 수정하지도 못한다. 공격자는 자신이 통제하는 호스트와 공개된 모든 것을 읽을 수 있다. 이 가정 아래에서, 어떤 배포의 *surface*가 한 세션 안에서 비공개 데이터 출처, 공격자가 통제하는 콘텐츠 출처, 공격자가 읽을 수 있는 목적지에 모두 닿을 때 그 배포는 위험하다. 우리는 그런 *surface*를 *trifecta-complete*라 부르고, 자기 도구만으로 충분한 제공자를 *capability-bundling*이라 부른다.

3 How Dangerous Are Real Configurations?

3.1 Study design

우리는 위에서 정의한 두 성질을, 사람들이 실제로 작성한 설정에서 측정한다. 현재 호스트들이 읽는 설정 형식 다섯 가지(*.mcp.json*, *.cursor/mcp.json*, *.vscode/mcp.json*, *claude_desktop_config.json*, 그리고 *.codex/config.toml*의 [*mcp_servers*] 테이블)를 공개 GitHub에서 검색하고, 각 파일을 메모리에서 파싱해 서버의 식별자와 실행 형태만 보관한다. 자격 증명은 저장하지 않는다. 검색은 85,065개의 파일을 보고했고, API의 질의당 상한 아래에서 22,552 개를 받을 수 있었으며, 21,015개가 파싱되고, 포크와 저장소 내 중복 서버 집합을 제거한 뒤 19,777 개가 남았다. 표 1가 코퍼스를 요약한다.

어떤 설정이 *trifecta-complete*인지 판단하려면 광고된 각 도구가 무엇에 닿는지 알아야 한다. 그래서 우리는 각 서버의 *tools/list* 핸드셰이크를 컨테이너 안에서 실행해 광고된 *surface*를 복원하고, 가장 자주 설정되는 서버 17개의 모든 도구에 대해 서버 자신의 소스 코드에서 효과를 도출하되 효과마다 파일과 줄 번호를 기록하며, 각 설정이 실제로 지정한 모드 플래그와 인자를 적용한다. 4절이 이 절차를 설명하며, 이는 INTERLOCK의 첫 단계다. 5절은 그 절차가 얼마나 신뢰할 만한지 보고한다. 이 절에서 필요한 것은 각 효과가 독자가 직접 확인할 수 있는 코드 한 줄로 추적된다는 사실뿐이다.

Table 2. Servers that make a configuration trifecta-complete by themselves, with the number of analysed configurations in which each appears.

Server	Configs	Why it alone suffices
@playwright/mcp	359	default tool runs agent code in the server process
github-mcp-server	183	private repos, third-party issues, public writes
server-github (archived)	172	same, with no mode flags at all
chrome-devtools-mcp	139	navigates to file:// and localhost, then exfiltrates
shadcn	121	fetches agent-chosen URLs, reads local files
supabase	81	user data in, agent-supplied code out
serena (default context)	28	host shell execution
mcp-server-fetch	26	no host restrictions on the URL
server-puppeteer	14	agent-supplied launch options reach spawn

3.2 Results

분석 가능한 설정의 대부분이 *trifecta-complete*이다. 판정 대상 서버 17개로만 구성된 설정 880개 – 우리가 수집한 다중 서버 설정의 10분의 1 – 가운데 **84.1%**(740개)가 *trifecta-complete*이다. 코드로 확정하지 못한 효과를 양극단으로 밀어도 값은 84.0%에서 85.6% 사이로만 움직인다. 사용자 자신의 데이터베이스와 워크스페이스 안의 레코드도 공격자가 쓸 수 있다고 보는 두 번째 위협 모델 변형에서도 값은 84.1%로 변하지 않는데, 해당 서버들이 이미 다른 경로로 세 효과 모두에 닿기 때문이다.

그것들을 위협하게 만드는 것은 조합이 아니다. *trifecta-complete*인 740개 설정 전부에서 단일 서버가 이미 *capability-bundling*이다. *trifecta-complete*가 되기 위해 서버 두 개 이상이 필요한 설정의 수는 0이다. 브라우저와 *fetch* 서버가 *file://*, *localhost*, 인트라넷 URL에 닿아 얻는 비공개 데이터 효과를 제외해도 그 비율은 3.3% 이하에 머물고, 여기에 더해 문서화된 원격 코드 실행 도구와 모든 로컬 URL 효과까지 무시해야 19.1%에 이르는데, 그 시점에는 남은 사례 대부분이 한 문서 서버의 자격증명 의존 효과에 기대고 있다. 17개 서버 중 9개가 단독으로 *capability-bundling*이며, 그중에는 수천 개 설정에 등장하는 브라우저 자동화, 코드 호스팅, 데이터베이스, 컴포넌트 레지스트리 서버가 있다(표 2).

존재하는 제어 수단은 쓰이지 않고, 주요 원인 서버에는 아예 없다. 코드 호스팅 서버는 읽기 전용 모드를 제공하지만 항목 189개 중 3개만 이를 설정하고 12개가 더 좁은 *toolset*을 선택한다. 데이터베이스 서버는 읽기 전용 모드를 제공하며 항목 116개 중 32개가 이를 설정한다. 코딩 에이전트 서버는 이름이 지정된 대부분의 *context*에서 셸 도구를 비활성화하는데, 항목 111개 중 84개가 그런 *context*를 선택한다. 채택률이 높은 유일한 사례다. 브라우저 자동화 서버에는 자기 프로세스 안에서 코드를 실행하는 도구를 제거하는 플래그가 없으며, *archived* 코드 호스팅 서버와 컴포넌트 레지스트리 서버, *fetch* 서버는 제한을 거는 플래그를 전혀 제공하지 않는다.

*surface*는 고정되어 있지 않다. 널리 설정되는 한 서버의 연속된 릴리스 64개 가운데 45개가 광고된 *surface*를 바꿨고 설명만 바꾼 것은 2개뿐이었다. 공개된 벤치마크는 서버 515개의 버전 9,273개에 걸쳐 초기 도구의 54.6%가 수정되거나 폐기되었다고 보고한다 [14]. 한편 *studio* 항목의 91.3%는 버전을 명시하지 않으므로 도구 뒤의 코드는 사용자가 아무 행동을 하지 않아도 바뀐다. 해시 기반 *pinning*은 이 모든 변화에 반응한다. 우리 코퍼스를 복원한 버전 이력에 대해 재생하면 18개월 창에서 설정당 약 23건의 변경 경고가 발생한다.

레지스트리 규모 조사와의 대조. 서버 1,360개의 도구 12,230개를 대상으로 한 조사는 한 서버가 세 능력을 동시에 가질 수 있고 그 경우 서버 사이 협조 없이 공격을 완성할 수 있다고 보고하면서, 그런 서버를 2개로 센다 [33]. 우리의 비율이 훨씬 높은 이유는 두 가지다. 그 조사는 레지스트리에서 서버를 균등하게 표집하지만 우리는 사람들이 실제로 설치하는 빈도로 가중치를 준다. 또한

우리는 도구 메타데이터가 아니라 소스 코드에서 효과를 도출하므로, 광고된 도구에서 도달 가능한 호스트 코드 실행이나 브라우저 · fetch 도구가 로컬 URL로 얻는 파일 내용처럼 메타데이터 수준 분류기가 보지 못하는 효과를 센다. 두 결과는 방향에서 일치하고 비율에서 같리며, 어느 쪽이든 단일 서버가 충분하다는 결론은 같다.

3.3 What this rules out

이 수치들은 설계 공간을 세 가지 방식으로 제약한다. 이 기저율에서 경고는 정보를 주지 못한다. 집합 단위 *trifecta* 검사는 이 설정들의 84%에 경고를 띄우고, 사용자가 할 수 있는 일은 무시하는 것뿐이다. 실제로 어떤 벤더 검사기는 바로 이 점을, 즉 대부분의 에이전트가 세 특성을 모두 가지므로 각 구성요소를 개별적으로 분석한다고 밝힌다 [24]. 서버 제거는 지나치게 거칠다. 판정을 좌우하는 서버들이 사용자가 의도적으로 설치한 것들이기 때문이다. 그리고 조합 지향 방어가 함의하는 해법인 제공자 사이 흐름 차단은 740개 설정 전부를 여전히 *trifecta-complete*로 남긴다. 남은 길은 사용자가 유지하는 제공자 내부에서 *surface*를 좁히는 것이며, 그것이 INTERLOCK이 하는 일이다.

4 Approach

4.1 Overview

INTERLOCK은 설정, 흐름 정책, 배포가 선언한 작업을 입력으로 받아, 호스트와 서버가 이미 제공하는 제어 수단 위의 *patch*를 반환한다. 절차는 세 단계다. *Summarize*는 신뢰도 순으로 정렬한 증거에서 도구별 효과 요약물을 도출한다. *Decide*는 설정이 유도한 *surface*에 대해 정책을 평가하고 각 금지 흐름을 증언하는 도구를 반환한다. *Repair*는 최소 비용 *patch* – 도구 단위 거부 항목, 서버 모드와 *toolset* 플러그, 인자 축소, 그리고 가장 비싼 선택지인 서버 제거 – 를 탐색해 금지된 흐름을 제거하면서 선언된 작업이 계속 동작하도록 한다. 이 논문은 *Summarize*를 구현 · 평가하며, *Decide*와 *Repair*는 여기서 명세하고 진행 중인 작업으로 남겨 두되, 두 단계에 관한 모든 진술은 그에 맞게 표시한다.

4.2 Summarize: trust-ranked effect summaries

이 단계는 광고된 도구마다 하나의 질문에 답한다. 이 도구는 SECRET, UNTRUSTED, SINK, HOSTEXEC 가운데 무엇에 닿을 수 있으며 그 증거는 무엇인가. 증거는 공격자가 얼마나 통제할 수 있는지에 따라 순위가 매겨진다. 설정 자신의 인자와 서버의 소스 코드가 1순위, 선언된 스키마와 *annotation*이 2순위이며, 자유 서술 설명은 효과를 낮추는 데 결코 쓰이지 않는다. 우리는 다만 쓸 수 있는데, 설명은 판정 대상인 당사자가 작성하기 때문이다. HOSTEXEC은 나머지 셋을 함의한다. 호스트에서의 코드 실행은 호스트가 닿을 수 있는 모든 것에 닿기 때문이다.

요약은 언어 모델이 생성하되 모든 주장에 *file:line* 증거를 인용해야 하며, 이후 결정적 검사가 가져온 소스에서 인용된 구간을 다시 읽어 걸러낸다. 인용이 가져온 트리 안에서 해석되지 않거나, 그 구간에 도구 이름이나 근거 설명이 지목한 식별자가 없으면, 그 주장은 유지되되 미확인으로 표시된다. 미확인 주장이 효과를 낮춰서는 안 되므로 라벨은 살아남지만, 검증된 것으로는 세지 않는다. 모델이 아예 판정하지 않은 도구에는 가장 보수적인 값인 HOSTEXEC을 부여한다. 모델이 라벨 없이 무해하다고 판정한 도구는 그 증거가 코드에서 해석될 때만 무해로 센다. 문서는 효과의 부재를 입증할 수 없기 때문이다. 이 구분이 이 단계의 출력을 그럴듯한 것이 아니라 감사 가능한 것으로 만들며, 5절은 그중 얼마가 검사를 통과하는지 측정한다.

실무적으로 중요한 세부가 둘 있다. 모델에게는 모든 줄에 실제 줄 번호를 붙인 소스를 보여준다. 줄 번호가 없으면 인용된 줄이 파일 뒤로 갈수록 어긋나고, 올바른 판정이 검증에 실패하기 때문이다. 또한 패키지 자신의 코드가 도구 이름을 전혀 언급하지 않는 경우 – 구현이 의존성에 있는 래퍼 패키지가 그렇다 – 그 이름을 언급하는 직접 의존성을 스크립트 실행을 끈 채 가져와 함께 보여준다. 파이프라인의 어느 지점에서든 제공자 코드는 실행되지 않는다.

Table 3. Outcome of deterministic re-checking over 34 servers and 433 advertised tools.

	Count	Share
Claims (labels asserted)	335	
verified in code	243	72.5% of claims
verified in documentation only	11	3.3% of claims
demoted (citation did not resolve)	81	24.2% of claims
Cleared with code evidence	65	
Cleared without code evidence	33	7.6% of tools
Unjudged tools	0	0.0% of tools
Judged names not in the surface	2	0.5% of tools
Servers usable (claim rate ≥ 0.70 , few clears, no unjudged)	27 / 34	79.4%
Cost of the run (USD)	8.53	

4.3 Decide and Repair (planned)

*Decide*는 설정이 지정한 값 수준 조건 – 읽기 전용 모드, toolset 선택, 경로 root, origin 허용 목록 – 을 적용한 뒤 설정이 유도한 surface에 대해 배포자의 정책을 평가하고, 금지된 흐름마다 그것을 증언하는 도구를 반환할 것이다. *Repair*는 선언된 작업의 보존을 조건으로 사용 가능한 제어 수단 위에서 최소 비용 patch를 탐색하고, 후보 patch마다 다시 판정해 결과가 가정이 아니라 검증된 것이 되게 하며, patch를 설정 diff로 내보낼 것이다. 우리는 두 단계를 서버 통째 제거, 서버 모드만 사용하는 방식, 이름 기반 휴리스틱 거부 목록, 동일 정책 하의 실행 시점 집행과 비교해, patch 전후의 benign utility, 공격 하 utility, 표적 공격 성공률을 측정할 계획이다.

5 Evaluation of the Summarize Stage

5.1 Research question and setup

여기서는 하나의 질문을 던진다. **RQ1**. 모델의 효과 판정 가운데 얼마가 제공자의 소스에 대한 결정적 재검사를 통과하며, 어떤 제공자에서 이 절차가 실패하는가? 우리는 광고된 surface를 복원할 수 있었던, 가장 자주 설정되는 npm 및 PyPI 서버 34개, 총 433개의 광고된 도구를 대상으로, 고정된 rubric과 JSON 스키마를 사용하는 Claude Opus 5, 패키지당 400 KB의 소스 예산, 그리고 4절에서 설명한 검사기로 프로파일을 만든다. 광고된 각 도구는 정확히 하나의 범주에 들어간다. 모델이 라벨을 주장했고 인용이 코드에서 해석된 경우(*verified*), 문서에서만 해석된 경우(*verified_doc*), 해석되지 않은 경우(*demoted*), 모델이 무해로 판정했고 코드 증거가 있는 경우(*cleared verified*) 또는 없는 경우(*cleared unverified*), 그리고 모델이 판정하지 않은 경우(*unjudged*)다. 광고된 surface에 없는 이름을 판정한 경우는 별도로 센다. 기준과 정의는 실행 전에 사전 등록했으며, 계획서가 정한 dry-run에서 발견된 측정 도구 변경은 모두 실행 이후가 아니라 이전에 기록했다.

5.2 Results

표 3가 RQ1에 답한다. 서버 34개 전체에서 라벨 주장의 72.5%가 코드로 검증된다. 판정되지 않은 도구는 없고, 이름 날조는 433개 중 2건으로 무시할 만하다. 손실의 대부분은 세 서버에서 나오며, 각각은 라벨링 오류가 아니라 구조적 이유로 실패한다. 하나는 실행기만 배포하고 컴파일된 바이너리를 내려받으므로 구현이 패키지 안에 전혀 없고, 인용 68건이 모두 문서를 가리킨다. 하나는 시작 시점에 인터페이스 명세에서 도구 이름을 생성하므로 그 이름이 소스 어디에도 없고 선택할 소스 파일이 없었다. 하나는 도구를 minified 번들로 구현하는데, 인용 35건 중 13건이 번들의 첫 줄을 가리키는 반면 인용된 식별자는 다른 위치에 있다. 구현 코드를 읽을 수 있었던 서버 27개로 한정하면 코드 검증률은 **90.7%**(268건 중 243건)다. 사용 가능 집합에서 빠진 나머지 네 서버는

절차의 실패가 아니다. 그 서버들의 도구는 모두 무해로 판정되었고 그중 셋은 전부 코드 증거에 기반했으며, 사전 등록한 사용 가능성 규칙이 주장된 라벨이 없는 서버를 사용 불가로 세기 때문이다.

5.3 Threats to validity

코퍼스. GitHub 코드 검색은 질의당 결과 수에 상한을 두고 표집이 아니라 관련도 순위로 반환하므로, 이 코퍼스는 배포의 무작위 표본이 아니다. 커밋된 설정은 사람들이 실제로 실행하는 설정과 다를 수도 있다. **판정 대상 집합.** 효과는 가장 자주 설정되는 서버 17개(측정)와 34개(평가)에 대해서만 도출했으므로, 유병률 수치는 인기 서버로 구성된 설정을 설명하며 롱테일을 설명하지 않는다. **위협 모델.** 유병률 수치는 최악 가정의 에이전트 아래에서 광고된 surface가 갖는 성질이다. 특정 배포가 공격을 당했다거나 공격이 성공한다고 주장하지 않으며, 악용 가능성 확인은 향후 과제다. **검사기.** 검사기는 한 방향으로 엄격하고 다른 방향으로 느슨하다. 강등 81건 중 약 9건은 인용 구간에 해당 식별자가 더 긴 표현 안에 실제로 존재하지만 토큰 일치가 이를 놓친 경우이고, 반대로 코드로 검증된 판정 308건 중 4건은 네 글자 이하의 토큰에 기대고 있다. **발췌.** 큰 파일에 대해서는 이름이 등장하는 지점 주변 창만 보여주므로, 큰 파일에 존재하는 도구 이름 11개는 모델에게 한 번도 보이지 않았다. 따라서 의존성 추적의 이득은 하한이다. **범위.** 우리의 결론은 설정 파일이 선언하는 MCP 서버에 대한 것이며, 에이전트 스킬로 일반화하지 않는다. 스킬은 광고된 도구 목록을 갖지 않으므로 여기서 쓴 측정 단위가 그대로 적용되지 않는다. **단일 모델.** 모든 요약은 한 시점의 한 모델에서 나왔다. 모델이나 시간에 따라 이 비율이 얼마나 달라지는지는 측정하지 않았다.

6 Related Work

아티팩트 하나를 검사하는 연구. 도구 오염 탐지기는 광고된 설명에서 숨겨진 지시, 이름 가로 채기, 유출 엔드포인트를 읽어낸다 [12]. 신뢰할 수 있는 설명을 재생성해 이 벡터를 제거할 수 있고 [31], 벤치마크는 실제 서버에서 그런 공격의 성공률을 정량화하며 [16, 27, 30], 정적 분석은 서버 내부의 taint 계열 결함을 찾고 [25], 동작 감사는 실행 중 도구를 관찰하며 [26], 이들은 아티팩트를 그 자신의 manifest나 코드에 비추어 판단한다. 우리의 입력은 여러 아티팩트를 조합한 설정이고, 출력은 그 설정에 대한 변경이다.

집합을 판단하는 연구. lethal trifecta 프레이밍은 위험한 조합을 명명하고 [28], toxic-flow 분석은 정책을 위반할 도구 순서를 구성해 점수화하며 [2], 조합 정책은 누적된 노출로 다음 호출이 위반이 되면 세션을 취소하고 [21], 레지스트리 규모 조사는 일부 서버가 세 능력을 동시에 가진다고 보고한다 [33]. 우리는 판단하는 성질을 공유하되 모집단과 출력에서 다르다. 레지스트리 아티팩트가 아니라 사람들이 작성한 설정을 대상으로 측정하고, 판정이나 세션 범위의 제한이 아니라 patch를 반환한다.

인접 생태계: 에이전트 스킬. 에이전트 스킬은 MCP와 다른 메커니즘이다. 스킬은 지시문 파일과 선택적 스크립트의 묶음이며, 도구 목록을 협상하는 프로토콜이 없고 광고된 schema도 없다. 그럼에도 공급망 관점의 위험은 닮아 있어서, 스킬에 대해서도 건전한 능력 상한이 추상 해석으로 계산되고 [3], 스킬 집합이 유도한 전이 시스템 위의 reachability가 능력 제한 cut과 짝지어지며 [29], 페이로드를 여러 스킬에 분산해 아티팩트 단위 검사를 회피하는 공격이 제시되었고 [32], 대규모 측정으로 취약점 유병률과 자격증명 유출, 공급망 오염이 보고되었다 [4, 11, 17, 18, 20]. 우리 결과는 이 생태계로 그대로 옮겨지지 않는다. 우리의 측정 단위는 설정 파일이 선언한 MCP 서버와 그 서버가 광고한 도구이며, 스킬에는 대응하는 광고된 surface가 없기 때문이다.

실행 시점에 에이전트를 제약하는 연구. 신뢰된 질의에서 제어 흐름과 데이터 흐름을 추출해 신뢰할 수 없는 데이터가 프로그램 흐름에 영향을 주지 못하게 하거나 [7], 기밀성과 무결성 라벨을 호출 단위로 추적·집행하거나 [6], 호출 단위 권한 정책으로 최소 권한을 강제하거나 [23], 질의 사이에 계획을 검사하거나 [9], 가드레일로 에이전트 루프를 감쌀 수 있다 [19]. 이들은 질이나 호출 단위로 판단하고, 호스트를 교체하거나 계측해야 하며, 설치된 surface는 그대로 둔다.

INTERLOCK은 이들과 상호보완적이다. 질의가 실행되기 전에 기성 호스트가 광고하는 것을 좁히며, 한 배포가 둘을 함께 쓸 수 있다.

기능 제약 아래 권한을 줄이는 연구. 브라우저 확장의 과다 권한은 선언된 manifest 권한을 코드가 실제로 호출하는 API와 비교해 탐지되고 [5], 프로그램 debloating은 테스트 스위트를 계속 통과시키면서 아티팩트를 줄인다 [10, 22]. Android의 앱 간 권한 유출에 대한 조합 분석은 설치된 집합을 분석하고 앱이 설치·갱신·삭제될 때 이를 다시 검사한다 [1, 13]. 우리 상황은 무엇을 바꿀 수 있는가에서 다르다. 아티팩트는 제3자의 것이라 우리가 고쳐 쓸 수 없으므로 축소는 배포의 설정에서 일어나며, 보존해야 할 성질은 아티팩트가 아니라 배포에 속한다.

7 Conclusion

에이전트 도구 보안 연구는 아티팩트 단위로 성숙해 왔고 집합 단위 질문도 명명되고 탐지되었지만, 사용자가 실제로 바꿀 수 있는 대상인 설정에는 고유한 분석이 없었다. 우리는 그 설정 모집단을 측정해, 분석 가능한 설정의 84.1%가 한 세션 안에서 비공개 데이터와 공격자가 통제하는 콘텐츠, 공격자가 읽을 수 있는 목적지에 닿으며, 그 전부에서 단일 서버로 충분하고, 존재하는 축소 수단은 대체로 쓰이지 않으며 주요 원인 서버에는 아예 없음을 확인했다. 우리는 설정에 대한 최소 권한 tool surface를 계산하는 INTERLOCK을 제시하고 그 첫 단계를 구현했다. 모든 주장이 인용된 소스에 대해 재검사되는 효과 요약으로, 전체의 72.5%가, 패키지가 실제로 실행하는 코드를 함께 배포하는 경우에는 90.7%가 검사를 통과한다. 실무적 함의는 두 가지다. 이 층위의 해법은 설정에 속하며, 사용자가 설치한 것의 대부분은 이미 내려받은 코드만으로 판정할 수 있다.

References

- [1] Hamid Bagheri, Alireza Sadeghi, Joshua Garcia, and Sam Malek. 2015. Covert: Compositional analysis of android inter-app permission leakage. *IEEE transactions on Software Engineering* 41, 9 (2015), 866–886.
- [2] Luca Beurer-Kellner, Marco Milanta, and Marc Fischer. 2025. Invariant Labs exposes novel prompt injection attack vulnerabilities, “toxic flows”, in agentic systems and MCP servers. <https://invariantlabs.ai/blog/toxic-flow-analysis>. Accessed 2026-09-16.
- [3] Varun Pratap Bhardwaj. 2026. Formal analysis and supply chain security for agentic AI skills. *arXiv preprint arXiv:2603.00195* (2026).
- [4] Zhihao Chen, Ying Zhang, Yi Liu, Gelei Deng, Yuekang Li, Yanjun Zhang, Jianting Ning, Leo Yu Zhang, Lei Ma, and Zhiqiang Li. 2026. How your credentials are leaked by LLM agent skills: An empirical study. *arXiv preprint arXiv:2604.03070* (2026).
- [5] Xiaoyu Cheng, Zhi Wang, Wanpeng Li, and Lifei Sun. 2026. PerCheck: An AST-Based Framework for Detecting Over-Privilege in Chrome Extensions. In *International Conference on Intelligent Computing*. Springer, 13–24.
- [6] Manuel Costa, Boris Köpf, Aashish Kolluri, Andrew Paverd, Mark Russinovich, Ahmed Salem, Shruti Tople, Lukas Wutschitz, and Santiago Zanella-Béguelin. 2025. Securing AI agents with information-flow control. *arXiv preprint arXiv:2505.23643* (2025).
- [7] Edoardo Debenedetti, Ilia Shumailov, Tianqi Fan, Jamie Hayes, Nicholas Carlini, Daniel Fabian, Christoph Kern, Chongyang Shi, Andreas Terzis, and Florian Tramèr. 2025. Defeating prompt injections by design. *arXiv preprint arXiv:2503.18813* (2025).
- [8] Shiva Gaire, Srijan Gyawali, Saroj Mishra, Suman Niroula, Dilip Thakur, and Umesh Yadav. 2026. Systematization of knowledge: Security and safety in the Model Context Protocol ecosystem. In *Intelligent Systems Conference*. Springer, 494–517.
- [9] Dylan Girrens and Guangjing Wang. 2026. SPA: Securing Persistent LLM Agents Across Queries with Plan-First Information-Flow Control. *arXiv preprint arXiv:2608.27234* (2026).
- [10] Kihong Heo, Woosuk Lee, Pardis Pashakhanloo, and Mayur Naik. 2018. Effective program debloating via reinforcement learning. In *Proceedings of the 2018 ACM SIGSAC conference on computer and communications security*. 380–394.
- [11] Florian Holzbauer, David Schmidt, Gabriel Gegenhuber, Sebastian Schrittwieser, and Johanna Ullrich. 2026. Context Matters: Repository-Aware Security Analysis of the Agent Skill Ecosystem. *arXiv preprint arXiv:2603.16572* (2026).
- [12] Gunjan Jain. 2026. *Detecting MCP Tool Poisoning and Rug-Pull Attacks in LLM Agent Architectures*. Technical Report. QCrypton.
- [13] Li Li, Alexandre Bartel, Tegawendé F Bissyandé, Jacques Klein, Yves Le Traon, Steven Arzt, Siegfried Rasthofer, Eric Bodden, Damien Oestreicher, and Patrick McDaniel. 2015. Iccta: Detecting inter-component privacy leaks in android apps. In *2015 IEEE/ACM 37th IEEE International Conference on Software Engineering*, Vol. 1. IEEE, 280–291.

- [14] Huanxi Liu, Kun Hu, Jiaqi Liao, Qiang Wang, Pengfei Qian, YuanZhao Zhai, Dawei Feng, Bo Ding, and Huaimin Wang. 2026. MCP-Evol-Bench: Benchmarking LLM agent performance across dynamic evolutions of MCP servers. *arXiv preprint arXiv:2607.14642* (2026).
- [15] Liwei Liu, Tianzhu Han, Zijian Liu, Zishu Dong, and Na Ruan. 2026. ShareLock: A Stealthy Multi-Tool Threshold Poisoning Attack Against MCP. *arXiv preprint arXiv:2606.27027* (2026).
- [16] Shi Liu, Xuehai Tang, Xikang Yang, Liang Lin, Biyu Zhou, Wenjie Xiao, and Wantao Liu. 2026. When the Manual Lies: A Realistic Benchmark to Evaluate MCP Poisoning Attacks for LLM Agents. In *2026 29th International Conference on Computer Supported Cooperative Work in Design (CSCWD)*. IEEE, 2090–2095.
- [17] Yi Liu, Zhihao Chen, Yanjun Zhang, Gelei Deng, Yuekang Li, Jianting Ning, and Leo Yu Zhang. 2026. "Do Not Mention This to the User": Detecting and Understanding Malicious Agent Skills in the Wild. *arXiv preprint arXiv:2602.06547* (2026).
- [18] Yi Liu, Weizhe Wang, Ruitao Feng, Yao Zhang, Guangquan Xu, Gelei Deng, Yuekang Li, and Leo Zhang. 2026. Agent skills in the wild: An empirical study of security vulnerabilities at scale. *arXiv preprint arXiv:2601.10338* (2026).
- [19] Nandhakumar Murugan. 2026. AgentShield: A Zero-Trust Runtime Guardrail Architecture for Autonomous Multi-Agent AI Systems with Bidirectional Context Synchronization. In *Zenodo (CERN European Organization for Nuclear Research)*. doi:10.5281/zenodo.22259021
- [20] Yubin Qu, Yi Liu, Tongcheng Geng, Gelei Deng, Yuekang Li, Leo Yu Zhang, Ying Zhang, and Lei Ma. 2026. Supply-chain poisoning attacks against LLM coding agent skill ecosystems. *arXiv preprint arXiv:2604.03081* (2026).
- [21] Chris Schneider, Kriti Faujdar, Philipp Schoenegger, and Ben Bariach. 2026. Securing multi-tool AI agent chains with dynamic, real-time compositional policies. *arXiv preprint arXiv:2607.03423* (2026).
- [22] Hashim Sharif, Muhammad Abubakar, Ashish Gehani, and Fareed Zaffar. 2018. TRIMMER: application specialization for code debloating. In *Proceedings of the 33rd ACM/IEEE International Conference on Automated Software Engineering*. 329–339.
- [23] Tianneng Shi, Jingxuan He, Zhun Wang, Hongwei Li, Linyu Wu, Wenbo Guo, and Dawn Song. 2025. Progent: Securing AI agents with privilege control. *arXiv preprint arXiv:2504.11703* (2025).
- [24] Snyk. 2026. agent-scan issue codes. <https://github.com/snyk/agent-scan/blob/main/docs/issue-codes.md>. Accessed 2026-09-16.
- [25] Pengyu Sun, Zifeng Kang, Qishu Jin, Enhao Huang, Xin Liu, Dakun Shen, and Song Li. 2026. VIPER-MCP: Detecting and Exploiting Taint-Style Vulnerabilities in Model Context Protocol Servers. *arXiv preprint arXiv:2605.21392* (2026).
- [26] Zhuoran Tan, Run Hao, Jeremy Singer, Yutian Tang, and Christos Anagnostopoulos. 2026. SandScope: a Behavioral Audit Layer for MCP Tools in LLM Agent Supply Chains. (2026).
- [27] Zhiqiang Wang, Yichao Gao, Yanting Wang, Suyuan Liu, Haifeng Sun, Haoran Cheng, Guanquan Shi, Haohua Du, and Xiangyang Li. 2026. Mcptox: A benchmark for tool poisoning on real-world mcp servers. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 40. 35811–35819.
- [28] Simon Willison. 2025. The lethal trifecta for AI agents: Private data, untrusted content, and external communication. <https://simonwillison.net/2025/Jun/16/the-lethal-trifecta/>. Accessed 2026-09-16.
- [29] Wujie Xiong, Rabimba Karanjai, Yang Lu, Weidong Shi, and Lei Xu. 2026. Reachability-Based Capability Confinement for LLM Agents under Indirect Prompt Injection. *arXiv preprint arXiv:2608.30041* (2026).
- [30] Yixuan Yang, Cuifeng Gao, Daoyuan Wu, Yufan Chen, Yingjiu Li, and Shuai Wang. 2025. MCPSecBench: A systematic security benchmark and playground for testing Model Context Protocols. *arXiv preprint arXiv:2508.13220* (2025).
- [31] Hengkai Ye, Zhechang Zhang, Jinyuan Jia, and Hong Hu. 2026. Trustdesc: Preventing tool poisoning in llm applications via trusted description generation. *arXiv preprint arXiv:2604.07536* (2026).
- [32] Puyu Zeng, Simeng Qin, Jingzhi Li, Ju Jia, Zheli Liu, and Xiaojun Jia. 2026. ColluSkill: Adversarial cross-skill composition for evading agent skill scanners. *arXiv preprint arXiv:2608.09732* (2026).
- [33] Shuli Zhao, Qinsheng Hou, Zihan Zhan, Yanhao Wang, Yuchong Xie, Yu Guo, Libo Chen, Shenghong Li, and Zhi Xue. 2026. Parasites in the toolchain: A large-scale analysis of attacks on the MCP ecosystem. In *2026 IEEE Symposium on Security and Privacy (SP)*.